

---

# Análise de Séries Temporais 2016/1

## Relatório 2: Modelos Dinâmicos

---

*Alunos:*

Ivani IVANOVA e  
Jonathas FERREIRA

*Professora:*

Alexandra M. SCHMIDT

Universidade Federal do Rio de Janeiro

Julho de 2016

# 1 Introdução


Como sequência do estudo realizado no Relatório 1, onde ajustamos modelos  $ARIMA(p, d, q)$  para a série de anomalias da temperatura global primeiro descritas em [3], buscamos ajustar um Modelo Dinâmico Linear para a mesma série. Faremos estimativas dos parâmetros do modelo por máxima verossimilhança e via fator de desconto. Por fim, analisaremos se o modelo ajustado é satisfatório.

## 2 Problema

Neste trabalho queremos ajustar um modelo linear dinâmico para a série  $Y_t$  (com variância amostral igual a 0.04742253) da anomalia da temperatura global (Gráfico 1) com a qual já trabalhamos anteriormente no Relatório 1.

---

**Gráfico 1:** Série temporal  $Y_t$  da anomalia da temperatura global



Para isso, supomos que  $Y_t$  segue um modelo da forma:

$$Y_t = F_t \theta_t + v_t, \quad v_t \sim \mathcal{N}(0, V_t) \quad (1)$$

$$\theta_t = G_t \theta_{t-1} + w_t, \quad w_t \sim \mathcal{N}_p(0, W_t) \quad (2)$$

Onde  $\theta_t$  é um vetor de  $p$  parâmetros e tal que no tempo  $t = 0$  tem uma distribuição a priori  $\mathcal{N}_p(m_0, C_0)$ ,  $F_t$  e  $G_t$  são matrizes conhecidas que especificam nosso modelo e  $V_t$  (no nosso caso,  $V_t$  é um escalar pois  $Y_t$  é unidimensional)

e  $W_t$  são matrizes de covariância das sequências independentes  $v_t$  e  $w_t$  que precisamos fixar ou estimar. Além disso, assumimos  $\theta_0$  independente de  $(v_t)$  e  $(w_t)$ .

Como nossos dados apontam uma tendência linear, vamos ajustar o modelo de crescimento linear, dado por:

$$Y_t = \mu_t + v_t, \quad v_t \sim \mathcal{N}(0, V) \quad (3)$$

$$\mu_t = \mu_{t-1} + \beta_{t-1} + w_{t,1}, \quad w_{t,1} \sim \mathcal{N}(0, \sigma_\mu^2) \quad (4)$$

$$\beta_t = \beta_{t-1} + w_{t,2}, \quad w_{t,2} \sim \mathcal{N}(0, \sigma_\beta^2) \quad (5)$$

com erros não correlacionados  $v_t, w_{t,1}$  e  $w_{t,2}$ .

Nesse caso, temos:

$$\theta_t = \begin{bmatrix} \mu_t \\ \beta_t \end{bmatrix}, \quad F = \begin{bmatrix} 1 & 0 \end{bmatrix}, \quad G = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}, \quad W = \begin{bmatrix} \sigma_\mu^2 & 0 \\ 0 & \sigma_\beta^2 \end{bmatrix} \quad (6)$$

com possível dependência temporal de  $\sigma_\mu^2$  e  $\sigma_\beta^2$ .

A análise que faremos a seguir estará baseada no Filtro de Kalman que enuncia:

**Proposição 1 (Filtro de Kalman) [1]:** Considere a MLD especificada por (1) e (2). Seja

$$\theta_{t-1}|y_{1:t-1} \sim \mathcal{N}(m_{t-1}, C_{t-1})$$

Então as seguintes afirmações são válidas.

(i) A distribuição de previsão um passo à frente de  $\theta_t$  dado  $y_{1:t-1}$  é Gaussiana, com parâmetros

$$\begin{aligned} a_t &= E(\theta_t|y_{1:t-1}) = G_t m_{t-1}, \\ R_t &= Var(\theta_t|y_{1:t-1}) = G_t C_{t-1} G_t' + W_t. \end{aligned} \quad (7)$$

(ii) A distribuição de previsão um passo à frente de  $Y_t$  dado  $y_{1:t-1}$  é Gaussiana, com parâmetros

$$\begin{aligned} f_t &= E(Y_t|y_{1:t-1}) = F_t a_t, \\ Q_t &= Var(Y_t|y_{1:t-1}) = F_t R_t F_t' + V_t. \end{aligned} \quad (8)$$

(iii) A distribuição filtragem de  $\theta_t$  dado  $y_{1:t}$  é Gaussiano, com parâmetros

$$\begin{aligned} m_t &= E(\theta_t|y_{1:t}) = a_t + R_t F_t' Q_t^{-1} e_t, \\ C_t &= Var(\theta_t|y_{1:t}) = R_t - R_t F_t' Q_t^{-1} F_t R_t, \end{aligned} \quad (9)$$

onde  $e_t = Y_t - f_t$  é o erro de previsão.

### 3 Estimação de $V$ e $W$ via máxima verossimilhança

Utilizando o método de estimação dos parâmetros por máxima verossimilhança descrito em [1] (p.144-147), com inicialização do algoritmo no ponto  $(0,0,0)$ , obtivemos as estimativas  $\hat{V} = 1.108414(10^{-2})$ ,  $\hat{\sigma}_\mu^2 = 2.275516(10^{-3})$  e  $\hat{\sigma}_\beta^2 = 1.565144(10^{-10})$  com desvios padrão estimados de  $2.997480(10^{-3})$ ,  $2.003502(10^{-3})$  e  $2.488127(10^{-8})$  respectivamente.


Utilizamos os parâmetros a priori  $m_0 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$  e  $C_0 = \begin{bmatrix} 10^7 & 0 \\ 0 & 10^7 \end{bmatrix}$ .

Com isso, os modelos que ajustamos segue as equações (3), (4), (5) e (6) com  $V = 1.108414(10^{-2})$  e  $W = \begin{bmatrix} 2.275516(10^{-3}) & 0 \\ 0 & 1.565144(10^{-10}) \end{bmatrix}$ .

A tendência filtrada, sua suavização com intervalos de 95 % de confiança e a previsão um passo a frente encontram-se nos gráficos a seguir.


---

**Gráfico 2:** Nível filtrado



---


**Gráfico 3:** Nível suavizado



Os gráficos da tendência filtrada e suavizada a seguir evidenciam que provavelmente não seria necessário incluir ela no modelo, no entanto, testamos modelos sem tendência e eles falham em se ajustar a série.


---

**Gráfico 4:** Tendência filtrada




---

**Gráfico 5:** Tendência Suavizada



---


**Gráfico 6:** Previsão 1 passo à frente



O Gráfico 7 mostra uma previsão de 10 anos à frente juntamente com valores simulados da série.

---

**Gráfico 7:** Previsão de 10 anos




### 3.1 Análise Residual

Esse modelo nos retorna resíduos que mostramos no Gráfico 8. O gráfico parece aceitável para a hipótese resíduos normais e descorrelacionados, porém vamos investigar isso mais a fundo.

---

**Gráfico 8:** Série temporal dos resíduos do modelo com parâmetros estimados por MV




O Gráfico 9 aponta que a hipótese de normalidade dos resíduos é razoável que é confirmada pelo teste de Shapiro-Wilk que retorna uma estatística  $W = 0.9943$  com valor-p de 0.941.

A função de autocorrelação amostral dos resíduos (Gráfico 10) aponta alguma correlação nos lags 1 e 3, mas não o suficiente para descartarmos o modelo. O teste runs aplicado aos resíduos retorna 0.209 e, portanto, não descartamos a hipótese de resíduos descorrelacionados.

---


**Gráfico 9:** QQ-Plot dos resíduos





---

**Gráfico 10:** Função de autocorrelação amostral dos resíduos



## 4 Estimação via Fator de Desconto

Neste modelo, supomos a variância observacional  $V = \sigma^2 = \phi^{-1}$  desconhecida onde  $\phi$  é a precisão observacional, além disso  $W_t$  será especificado por fatores de desconto. Nesse modelo, temos:

$$Y_t = F_t \theta_t + v_t, \quad v_t \sim \mathcal{N}(0, V) \quad (10)$$

$$\theta_t = G_t \theta_{t-1} + w_t, \quad w_t \sim \mathcal{N}_p(0, VW_t^*) \quad (11)$$

Onde,  $\theta_0|V \sim \mathcal{N}(m_0, VC_0^*)$  e  $V^{-1} = \phi \sim \text{Gama}(\alpha_0, \beta_0)$  com  $\phi$  sendo a precisão amostral.

Como a variância amostral de  $Y_t$  é igual a 0.04742253 e, portanto, a precisão amostral igual a 21.08702, especificamos os parâmetros  $\alpha_0 = 2$  e  $\beta_0 = 0.1$  da priori de  $\phi$ .

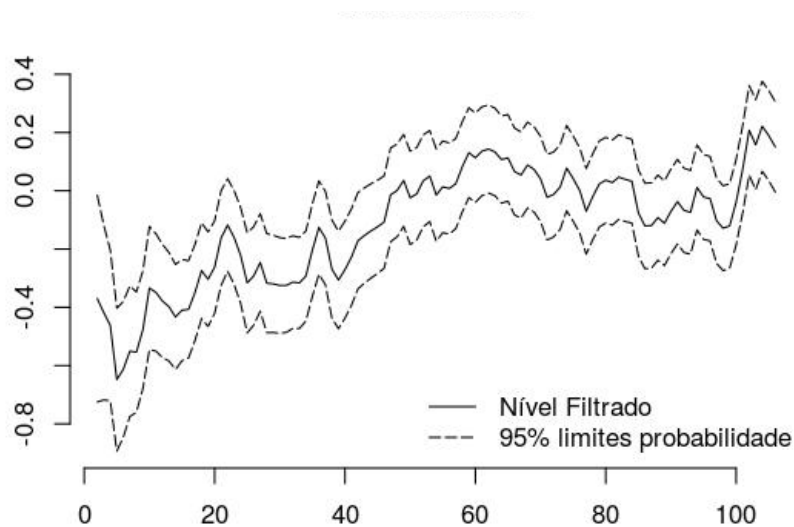
Consideramos um fator de desconto  $\delta \in (0, 1]$  que pode ser interpretada como a porcentagem de informação que passa de  $t-1$  para  $t$ .  $\delta = 1$  significa  $W_t = 0$  e não há perda de informação, para  $\delta < 1$  a perda de informação cresce a medida que  $\delta$  decresce. Atribuímos um valor de 0.8 para o fator de desconto tanto para o nível  $\mu_t$  quanto para a tendência  $\beta_t$ . Esse valor foi escolhido após a análise de resíduos do ajuste de modelos com diferentes fatores de desconto. Escolhemos os hiperparâmetros a priori  $m_0 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$ ,  $C_0^* = \begin{bmatrix} 10^7 & 0 \\ 0 & 10^7 \end{bmatrix}$

$\alpha_0 = 2$  e  $\beta_0 = 0.1$  pois a precisão amostral foi estimada em 21.088.

Os gráficos a seguir mostram as estimativas filtradas e suavizadas do nível, além da previsão um passo a frente, todos com intervalos de confiança de 95%.

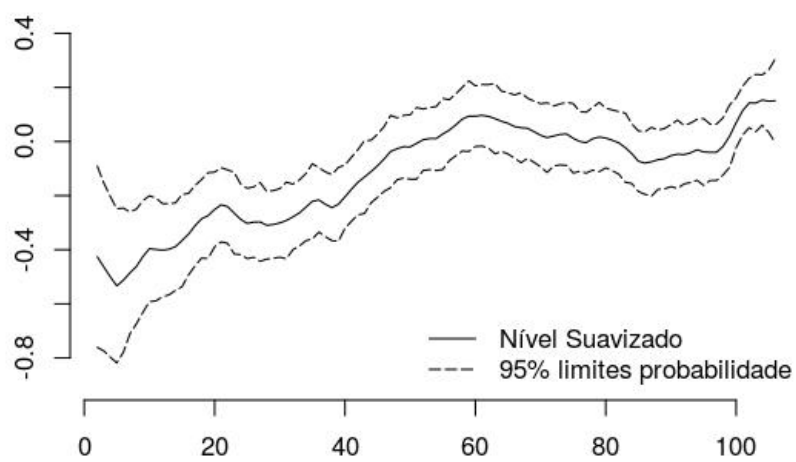
---

**Gráfico 11:** Nível filtrado




---

**Gráfico 12:** Nível suavizado



---

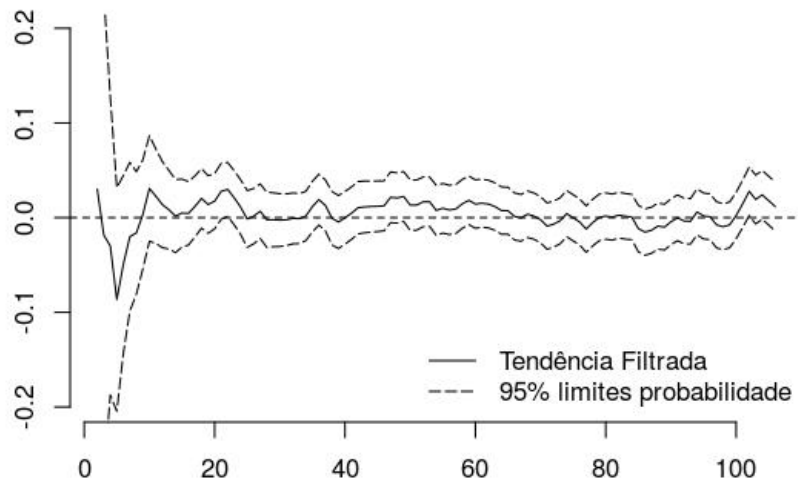
**Gráfico 13:** Previsão 1 passo à frente



Assim como na estimação de  $V$  e  $W$  via verossimilhança obtemos que provavelmente não seria necessário incluir a tendência no modelo, mas como modelos sem ela falham em se ajustar a série, optamos por usar um modelo com tendência.


---

**Gráfico 14:** Tendência filtrada



---


**Gráfico 15:** Tendência suavizada



O gráfico seguinte mostra a variância  $\sigma^2$  filtrada.

---

**Gráfico 16:** Variância filtrada




## 4.1 Análise Residual

Os resíduos do modelo estão explicitados no Gráfico. O QQ-Plot e a função de autocorrelação amostral não sugerem evidências muito claras contra normalidade ou decorrelação (apesar de termos alguma correlação no lag 1 e 3). O teste Runs retorna um valor-p de 0.204 e o teste de Shapiro-Wilk retorna um valor-p igual a 0.9186. Logo, não rejeitamos nem a hipótese de decorrelação nem a de normalidade dos resíduos.


---

**Gráfico 17:** Resíduos do modelo com parâmetros estimados via fator de desconto




---

**Gráfico 18:** QQ-Plot dos resíduos



---

**Gráfico 19:** Função de autocorrelação amostral dos resíduos



## 5 Conclusão

Neste trabalho, ajustamos um modelo linear dinâmico com parâmetros estimados por duas formas diferentes: máxima verossimilhança e com fatores de desconto. Esses modelos nos propiciam integrar a informação a cada instante no modelo, ao contrário dos modelos ARIMA, estáticos, com os quais modelamos a mesma série no Relatório 1. Vemos que a previsão feita parece melhor e captura a tendência da série.



## 6 Bibliografia

- [1] - Petris, G., Petrone, S. & Campagnoli P. - *Dynamic Linear Models with R*, Springer, 2009.
- [2] - Cryer, J. D. & Chan, K. S. - *Time Series Analysis With Applications in R*, Springer, 2nd edition, 2010.
- [3] - Hansen, J. & Lebedeff, S. - *Global Trends of Measured Surface Air Temperature*, Journal of Geophysical Research, Vol. 92, NO. D11, pages 13,345-13,372, 1987.
- [4] - <https://datamarket.com/data/list/?q=provider:tsdl>